



# THYROID CANCER RISK DATASET


DATA PREPARATION  
AND DATA MINING



BY NOW WANT TO  
PRESS GRAB



# ABOUT DATASET



ตัวแปร	คำอธิบายข้อมูล	ตัวแปร	คำอธิบายข้อมูล
Patient_ID	หมายเลขระบุผู้ป่วยแต่ละราย	Radition_Exposure	ประวัติการได้รับรังสี (มี/ไม่มี)
Age	อายุของผู้ป่วย	Iodine_Deficiency	การมีภาวะขาดไอโอดีน (มี/ไม่มี)
Gender	เพศของผู้ป่วย (ชาย/หญิง)	Smoking	ผู้ป่วยสูบบุหรี่หรือไม่ (ใช่/ไม่ใช่)
Country	ประเทศที่อยู่อาศัย	Obesity	ผู้ป่วยเป็นโรคอ้วนหรือไม่ (ใช่/ไม่ใช่)
Ethnicity	สัญชาติของผู้ป่วย	Diabetes	ผู้ป่วยเป็นโรคเบาหวานหรือไม่ (ใช่/ไม่ใช่)
Family_History	ผู้ป่วยมีประวัติครอบครัวเป็นมะเร็งต่อมไทรอยด์หรือไม่ (มี/ไม่มี)	TSH_Level	ระดับฮอร์โมนกระตุ้นต่อมไทรอยด์ (μIU/mL)
T3_Level	ระดับไตรไอโอโดไทรโอนีน (ng/dL)	T4_Level	ระดับไทรอกซีน (μg/dL)
Nodule_Size	ขนาดของก้อนเนื้อในต่อมไทรอยด์ (ซม.)	Thyroid_Cancer_Risk	ความเสี่ยงโดยประมาณของมะเร็งต่อมไทรอยด์ (ต่ำ/กลาง/สูง)
Diagnosis	การวินิจฉัยขั้นสุดท้าย (ไม่ร้ายแรง/ร้ายแรง)		

# DATA PREPARATION

```
thyroid_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 212691 entries, 0 to 212690
Data columns (total 17 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Patient_ID            212691 non-null int64   
1   Age                   212691 non-null int64   
2   Gender                212691 non-null object  
3   Country               212691 non-null object  
4   Ethnicity             212691 non-null object  
5   Family_History        212691 non-null object  
6   Radiation_Exposure    212691 non-null object  
7   Iodine_Deficiency     212691 non-null object  
8   Smoking               212691 non-null object  
9   Obesity               212691 non-null object  
10  Diabetes              212691 non-null object  
11  TSH_Level             212691 non-null float64  
12  T3_Level              212691 non-null float64  
13  T4_Level              212691 non-null float64  
14  Nodule_Size           212691 non-null float64  
15  Thyroid_Cancer_Risk   212691 non-null object  
16  Diagnosis             212691 non-null object  
dtypes: float64(4), int64(2), object(11)
memory usage: 27.6+ MB
```

```
thyroid_df.head()
```

	Patient_ID	Age	Gender	Country	Ethnicity	Family_History	Radiation_Exposure	Iodine_Deficiency	Smoking
0	1	66	Male	Russia	Caucasian	No	Yes	No	No
1	2	29	Male	Germany	Hispanic	No	Yes	No	No
2	3	86	Male	Nigeria	Caucasian	No	No	No	No
3	4	75	Female	India	Asian	No	No	No	No
4	5	35	Female	Germany	African	Yes	Yes	No	No

Obesity	Diabetes	TSH_Level	T3_Level	T4_Level	Nodule_Size	Thyroid_Cancer_Risk	Diagnosis
No	No	9.37	1.67	6.16	1.08	Low	Benign
No	No	1.83	1.73	10.54	4.05	Low	Benign
No	No	6.26	2.59	10.57	4.61	Low	Benign
No	No	4.10	2.62	11.04	2.46	Medium	Benign
No	No	9.10	2.11	10.71	2.11	High	Benign



# DATA PREPARATION

## แบ่งช่วงอายุ

- Child = < 12 yrs
- Teen = 13-19 yrs
- Adult = 20-39 yrs
- Middle Age Adult = 40-59 yrs
- Senior Adult = 60+

```
[ ] def age_group(age):  
    if age < 12:  
        return 'Child'  
    elif 13 <= age < 20:  
        return 'Teen'  
    elif 20 <= age < 40:  
        return 'Adult'  
    elif 40 <= age < 60:  
        return 'Adult'  
    else:  
        return 'Senior'  
  
# สร้างคอลัมน์ใหม่สำหรับช่วงอายุ  
thyroid_df['Age_Group'] = thyroid_df['Age'].apply(age_group)
```

Smoking	Obesity	Diabetes	TSH_Level	T3_Level	T4_Level	Nodule_Size	Thyroid_Cancer_Risk	Diagnosis	Age_Group
No	No	No	9.37	1.67	6.16	1.08	Low	Benign	Senior
No	No	No	1.83	1.73	10.54	4.05	Low	Benign	Adult
No	No	No	6.26	2.59	10.57	4.61	Low	Benign	Senior
No	No	No	4.10	2.62	11.04	2.46	Medium	Benign	Senior
No	No	No	9.10	2.11	10.71	2.11	High	Benign	Adult

## การแบ่งขนาดก้อนเนื้อ

- ถ้า nd น้อยกว่า 1 → คัดคำว่า '< 1'
- ถ้า nd อยู่ในช่วง 1 ถึง น้อยกว่า 2 → คัดคำว่า '1'
- ถ้า nd อยู่ในช่วง 2 ถึง น้อยกว่า 3 → คัดคำว่า '2'
- ถ้า nd อยู่ในช่วง 3 ถึง น้อยกว่า 4 → คัดคำว่า '3'
- ถ้า nd อยู่ในช่วง 4 ถึง น้อยกว่า 5 → คัดคำว่า '4'
- ถ้า nd อยู่ในช่วง 5 ถึง น้อยกว่า 6 → คัดคำว่า '5'
- ถ้า nd มากกว่าหรือเท่ากับ 6 → คัดคำว่า '>= 5'

```
[ ] def Nodule_Size(nd):  
    if nd < 1:  
        return '< 1'  
    elif 1 <= nd < 2:  
        return '1'  
    elif 2 <= nd < 3:  
        return '2'  
    elif 3 <= nd < 4:  
        return '3'  
    elif 4 <= nd < 5:  
        return '4'  
    elif 5 <= nd < 6:  
        return '5'  
    else:  
        return '>= 5'  
  
thyroid_df['Nodule_Size_int'] = thyroid_df['Nodule_Size'].apply(Nodule_Size)  
thyroid_df.head()
```

Diabetes	TSH_Level	T3_Level	T4_Level	Nodule_Size	Thyroid_Cancer_Risk	Diagnosis	Age_Group	Nodule_Size_int
No	9.37	1.67	6.16	1.08	Low	Benign	Senior	1
No	1.83	1.73	10.54	4.05	Low	Benign	Adult	4
No	6.26	2.59	10.57	4.61	Low	Benign	Senior	4
No	4.10	2.62	11.04	2.46	Medium	Benign	Senior	2
No	9.10	2.11	10.71	2.11	High	Benign	Adult	2

## แบ่งช่วง tsh

- ถ้า tsh น้อยกว่า 0.4 → คัดคำว่า 'Low'
- ถ้า tsh อยู่ในช่วง 0.4 ถึง 4 (รวม 4) → คัดคำว่า 'Normal'
- ถ้า tsh อยู่ในช่วงมากกว่า 4 ถึง 10 (รวม 10) → คัดคำว่า 'High'

```
[ ] print(thyroid_df['T4_Level'].unique())  
  
[ ] def categorize_tsh_level(tsh):  
    if tsh < 0.4:  
        return 'Low'  
    elif 0.4 <= tsh <= 4:  
        return 'Normal'  
    elif 4 < tsh <= 10:  
        return 'High'  
  
# ใช้ฟังก์ชันในการแบ่งกลุ่มข้อมูล  
thyroid_df['TSH_Category'] = thyroid_df['TSH_Level'].apply(categorize_tsh_level)  
thyroid_df.head()
```

_Level	T3_Level	T4_Level	Nodule_Size	Thyroid_Cancer_Risk	Diagnosis	Age_Group	Nodule_Size_int	TSH_Category
9.37	1.67	6.16	1.08	Low	Benign	Senior	1	High
1.83	1.73	10.54	4.05	Low	Benign	Adult	4	Normal
6.26	2.59	10.57	4.61	Low	Benign	Senior	4	High
4.10	2.62	11.04	2.46	Medium	Benign	Senior	2	High
9.10	2.11	10.71	2.11	High	Benign	Adult	2	High

# DATA PREPARATION

## แบ่งช่วง T3

เงื่อนไขการจำแนกตามอายุและค่าปกติของ T3:

อายุ 1–5 ปี: ค่าปกติ 1.06–2.03

อายุ 6–10 ปี: ค่าปกติ 1.04–1.83

อายุ 11–14 ปี: ค่าปกติ 0.68–1.86

อายุ 15–17 ปี: ค่าปกติ 0.71–1.75

อายุ 18–99 ปี: ค่าปกติ 0.79–1.65

```
def determine_t3_status(row):
    age = row['Age']
    t3_level = row['T3_Level']

    if 1 <= age <= 5:
        if t3_level < 1.06:
            return 'Low'
        elif t3_level > 2.03:
            return 'High'
        else:
            return 'Normal'
    elif 6 <= age <= 10:
        if t3_level < 1.04:
            return 'Low'
        elif t3_level > 1.83:
            return 'High'
        else:
            return 'Normal'
    elif 11 <= age <= 14:
        if t3_level < 0.68:
            return 'Low'
        elif t3_level > 1.86:
            return 'High'
        else:
            return 'Normal'
    else:
        return 'Normal'
```

```
elif 15 <= age <= 17:
    if t3_level < 0.71:
        return 'Low'
    elif t3_level > 1.75:
        return 'High'
    else:
        return 'Normal'
elif 18 <= age <= 99:
    if t3_level < 0.79:
        return 'Low'
    elif t3_level > 1.65:
        return 'High'
    else:
        return 'Normal'
else:
    return 'Age out of range'
```

```
thyroid_df['T3_Category'] = thyroid_df.apply(determine_t3_status, axis=1)
thyroid_df.head()
```

#	T4_Level	Nodule_Size	Thyroid_Cancer_Risk	Diagnosis	Age_Group	Nodule_Size_int	TSH_Category	T3_Category
.67	6.16	1.08	Low	Benign	Senior	1	High	High
.73	10.54	4.05	Low	Benign	Adult	4	Normal	High
.59	10.57	4.61	Low	Benign	Senior	4	High	High
.62	11.04	2.46	Medium	Benign	Senior	2	High	High
.11	10.71	2.11	High	Benign	Adult	2	High	High

## แบ่งช่วง T4

- ถ้า t4 น้อยกว่า 4.5 → คัดค่า 'Low'
- ถ้า t4 อยู่ในช่วง 4.5 ถึง 11.5 (รวม 11.5) → คัดค่า 'Normal'
- ถ้า t4 มากกว่า 11.5 → คัดค่า 'High'

```
[ ] def categorize_t4_level(t4):
    if t4 < 4.5:
        return 'Low'
    elif 4.5 <= t4 <= 11.5:
        return 'Normal'
    else:
        return 'High'

# ใช้ฟังก์ชันในการแบ่งกลุ่มข้อมูล
thyroid_df['T4_Category'] = thyroid_df['T4_Level'].apply(categorize_t4_level)
thyroid_df.head()
```

Nodule_Size	Thyroid_Cancer_Risk	Diagnosis	Age_Group	Nodule_Size_int	TSH_Category	T3_Category	T4_Category
1.08	Low	Benign	Senior	1	High	High	Normal
4.05	Low	Benign	Adult	4	Normal	High	Normal
4.61	Low	Benign	Senior	4	High	High	Normal
2.46	Medium	Benign	Senior	2	High	High	Normal
2.11	High	Benign	Adult	2	High	High	Normal

## One - hot Encoding

```
from sklearn.preprocessing import LabelEncoder
# สร้าง LabelEncoder object
le = LabelEncoder()

# สร้าง Dictionary เพื่อเก็บ Mapping ของแต่ละคอลัมน์
label_mappings = {}

# ตรวจสอบและแปลงเฉพาะคอลัมน์ที่เป็น object
for column in thyroid_df.columns:
    if thyroid_df[column].dtype != 'object':
        thyroid_df[column] = thyroid_df[column].astype('object')

# เข้ารหัสและแสดง mapping
for column in thyroid_df.columns:
    if thyroid_df[column].dtype == 'object':
        thyroid_df[column] = le.fit_transform(thyroid_df[column])
        label_mappings[column] = dict(zip(le.classes_, le.transform(le.classes_)))
        print(f"Value Encoding for column '{column}':")
        for original, encoded in label_mappings[column].items():
            print(f"    {original}: {encoded}")
        print()
```

Middle Eastern: 4

Value Encoding for column 'Family\_History':  
2: 0  
No: 1  
Yes: 2

Value Encoding for column 'Radiation\_Exposure':  
No: 0  
Yes: 1

Value Encoding for column 'Iodine\_Deficiency':  
No: 0  
Yes: 1

Value Encoding for column 'Smoking':  
No: 0  
Yes: 1

Value Encoding for column 'Obesity':  
No: 0  
Yes: 1

# Reference

## แบ่งช่วงอายุ

### Stages of Life: Health for Every Age

Check back to the INTEGRIS Health On Your Health blog for the latest health and wellness news for all Oklahomans.

[integrityhealth /](#)

## การแบ่งขนาดก้อนเนื้อ



### What Size Thyroid Nodule Should You Worry About

Thyroid nodules are a common condition among adult Americans, but at what size should you start worrying about them?

[Associated Endocrinologists](#) / May 23, 2022

## แบ่งช่วง tsh t3 t4

### T3, T4, TSH Test Normal Range: TSH (Thyroid) Test | Dr. B. Lal Labs

Read this blog to learn about the T3, T4, and TSH test normal range and how they affect your thyroid health.

[hlallah.com](#)

ASSOCIATION RULE

GROUPBY PATIENT\_ID

Rule		Support	Confidence	Lift
T4 = Normal	Diagnosis = Malignant	0.93	1.0	1.0
Diabetes = No	Diagnosis = Malignant	0.80	1.0	1.0
T3 = High	Diagnosis = Malignant	0.61	1.0	1.0
TSH = High	Diagnosis = Malignant	0.61	1.0	1.0

Rule		Support	Confidence	Lift
Diabetes = No , T4 = Normal	Diagnosis = Malignant	0.75	1.0	1.0
Gender = Female	Diagnosis = Malignant	0.60	1.0	1.0
T4 = Normal , Smoking = No , Diabetes = No	Diagnosis = Malignant	0.57	1.0	1.0



ASSOCIATION RULE

GROUPBY ETHNICITY

Ethnicity	Rule		Support	Confidence	Lift
Asian / Caucasion / African / Hispanic	T4 = Normal	Diagnosis = Malignant	0.93	1.0	1.0
Asian	Thyroid_Cancer_Risk = High	Diagnosis = Malignant	0.70	1.0	1.0
Caucasian	Family_History = No	Diagnosis = Malignant	0.70	1.0	1.0
African	T3 = High	Diagnosis = Malignant	0.62	1.0	1.0

ASSOCIATION RULE

GROUPBY ETHNICITY

Ethnicity	Rule		Support	Confidence	Lift
African	TSH = High	Diagnosis = Malignant	0.60	1.0	1.0
Middle Eastern / Hispanic	T4 = Normal	Diagnosis = Malignant	0.93	1.0	1.0
Middle Eastern	T3 = High	Diagnosis = Malignant	0.60	1.0	1.0
Hispanic	TSH = High	Diagnosis = Malignant	0.61	1.0	1.0

# MODEL

DECISION TREE

NAIVE BAYES


LOGISTIC REGRESSION

Value Encoding for column

ตัวแปร	คำอธิบายข้อมูล	ตัวแปร	คำอธิบายข้อมูล
Diagnosis	Benign: 0 ,Malignant: 1	Radition_Exposure	No: 0 , Yes: 1
Age	Adult: 0, Senior: 1, Teen: 2	Iodine_Deficiency	No: 0 , Yes: 1
Gender	Female: 0, Male: 1	Smoking	No: 0 , Yes: 1
Country	Brazil: 0 ,China: 1 ,Germany: 2 ,India: 3 ,Japan: 4 ,Nigeria: 5 ,Russia: 6 ,South Korea: 7 ,UK: 8 ,USA: 9	Obesity	No: 0 , Yes: 1
Ethnicity	African: 0 ,Asian: 1 ,Caucasian: 2 ,Hispanic: 3 ,Middle Eastern: 4	Diabetes	No: 0 , Yes: 1
Family_History	No: 0 , Yes: 1	TSH_Category	High: 0 ,Low: 1 ,Normal: 2
T3_Category	High: 0 ,Low: 1 ,Normal: 2	T4_Category	High: 0 ,Low: 1 ,Normal: 2
Nodule_Size	1: 0 ,2: 1 ,3: 2 ,4: 3 ,5: 4 ,< 1: 5	Thyroid_Cancer_Risk	High: 0 , Low: 1 ,Medium: 2



# Correlation Matrix of Thyroid Dataset



## Features ที่นำเข้าและ Target

**X**

Ethnicity, Family\_History, Thyroid\_Cancer\_Risk, Radiation\_Exposure, Iodine\_Deficiency

**Y**

Diagnosis

Value counts ของ y\_train  
(Diagnosis )

Benign

130631

Malignant

39521

170,152

Value counts ของ y\_test  
(Diagnosis )

Benign

32565

Malignant

9974

42,539

212,691

แบ่งข้อมูล Train/Test

Train

80%

Test

20%

## DECISION TREE

## Result


```
Best Parameters: {'class_weight': None, 'max_depth': 5, 'min_samples_leaf': 1, 'min_samples_split': 2}
Best F1 Score (Malignant): 0.7914656802056921
Cross-validation scores: [0.95899483 0.95917324 0.95839561 0.95809518 0.95805547]
Mean CV ROC-AUC: 0.958542863047437
Mean CV Accuracy: 0.915757680031982
```

```
Classification Report:
              precision    recall  f1-score   support


     0           0.91       0.99       0.95       32565
     1           0.94       0.70       0.80        9974

 accuracy              0.92       0.92       0.91       42539
 macro avg           0.93       0.84       0.87       42539
weighted avg           0.92       0.92       0.91       42539
```

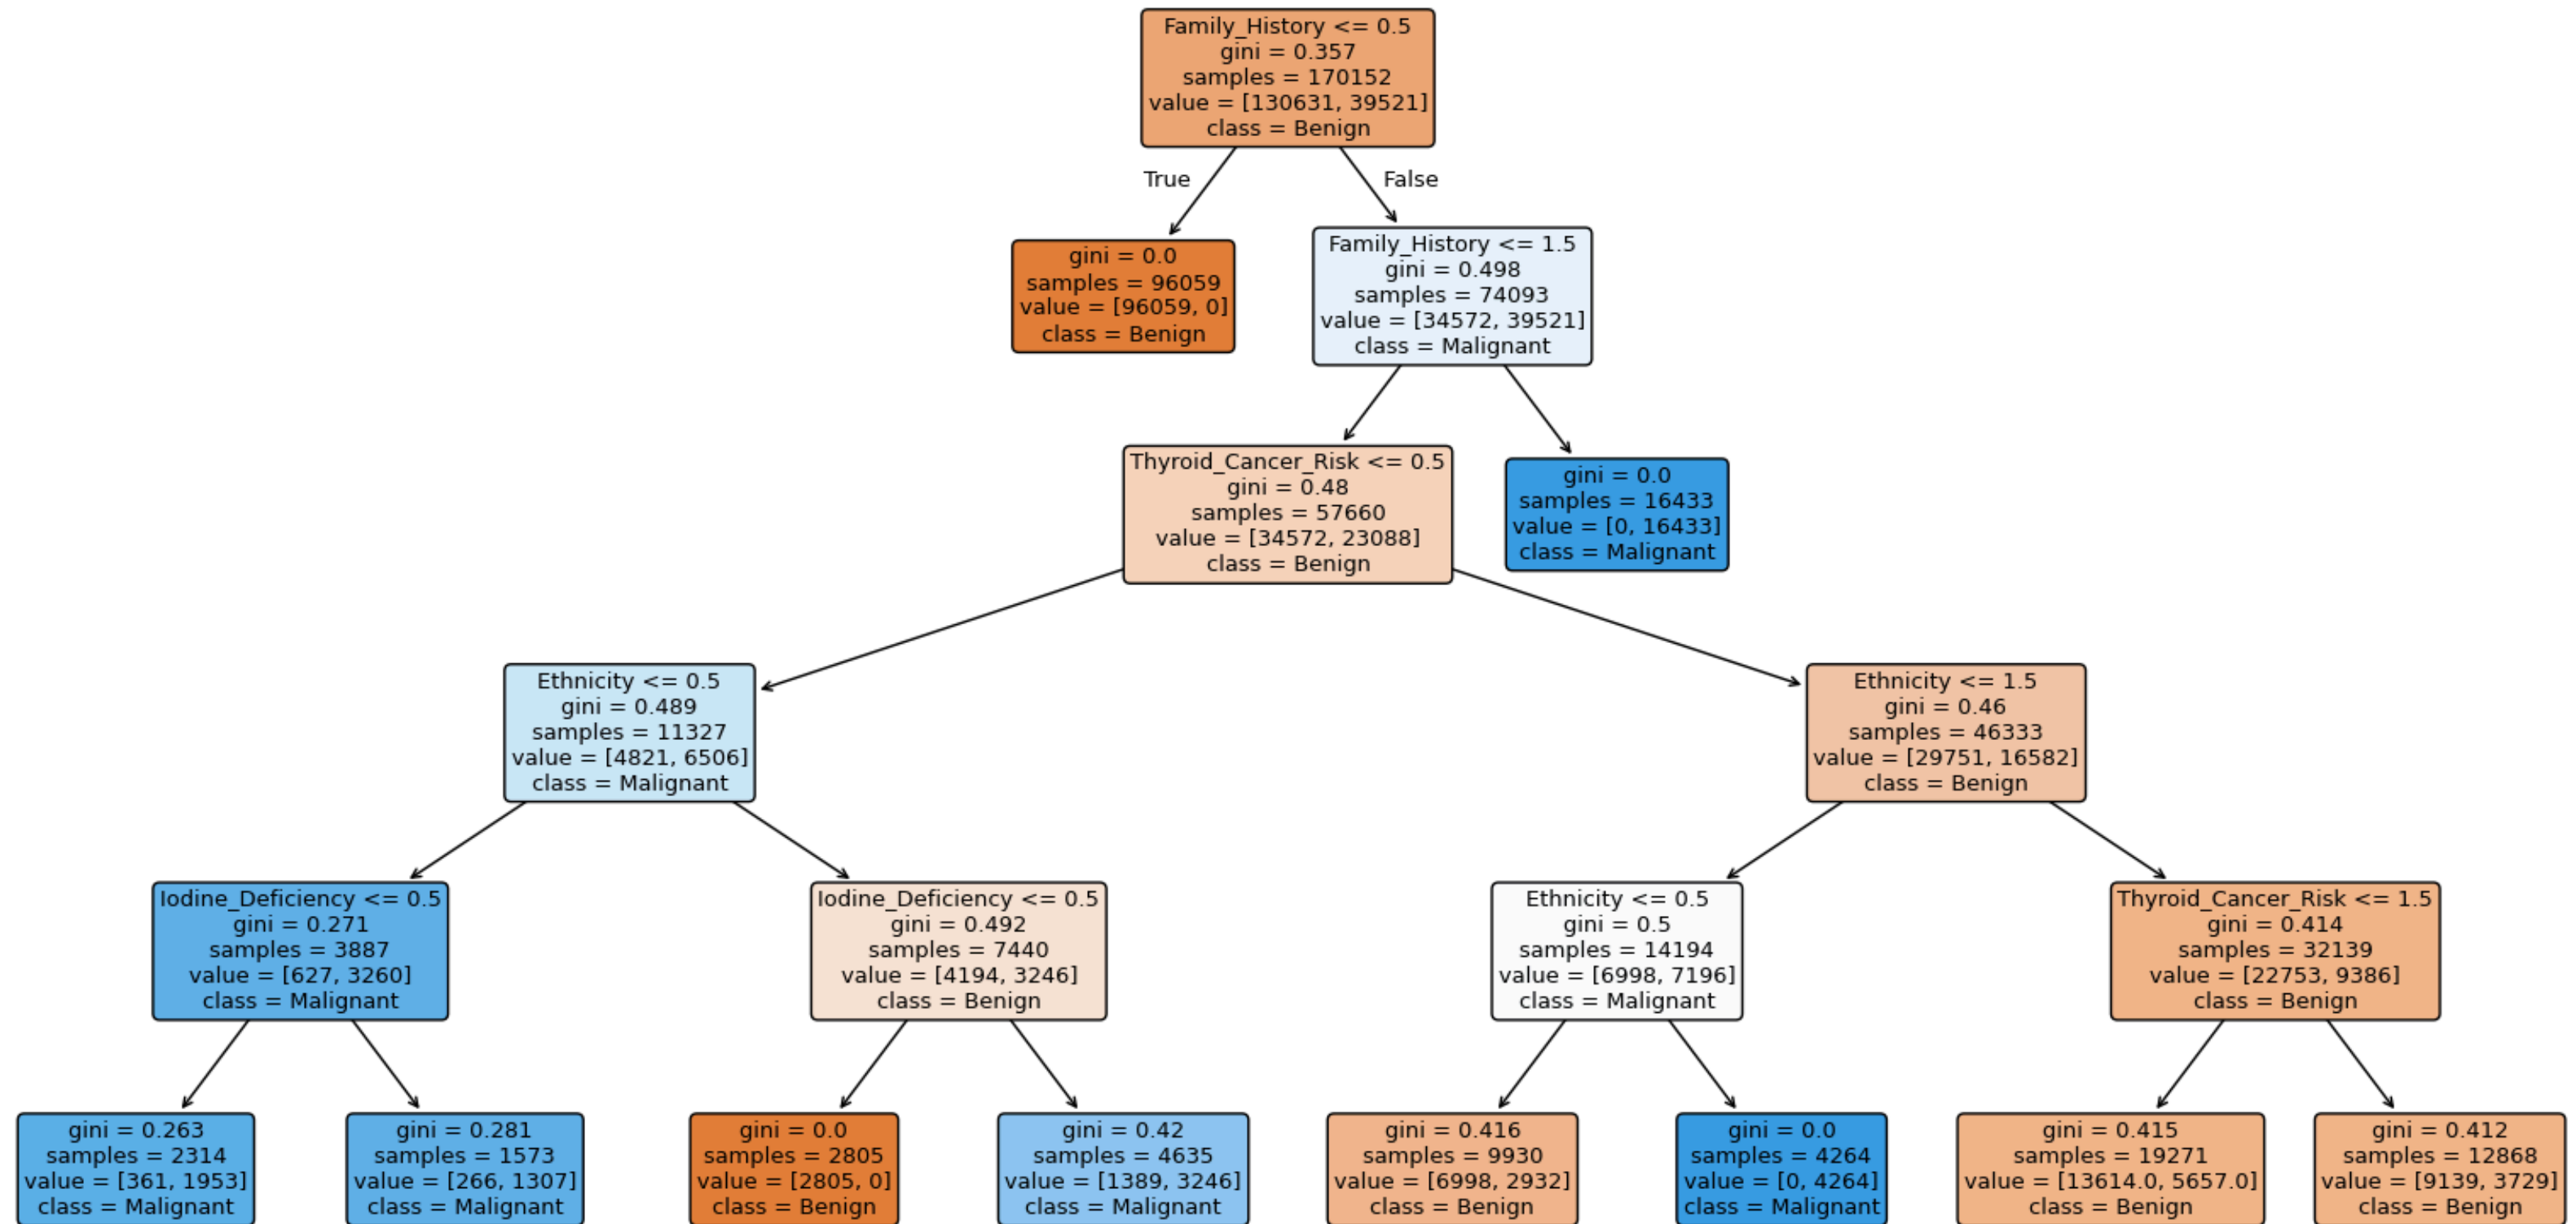
```
Test Set Accuracy: 0.9177695761536473
Test Set ROC-AUC Score: 0.9600313494342161
```



Receiver Operating Characteristic







## NAIVE BAYES

## Result

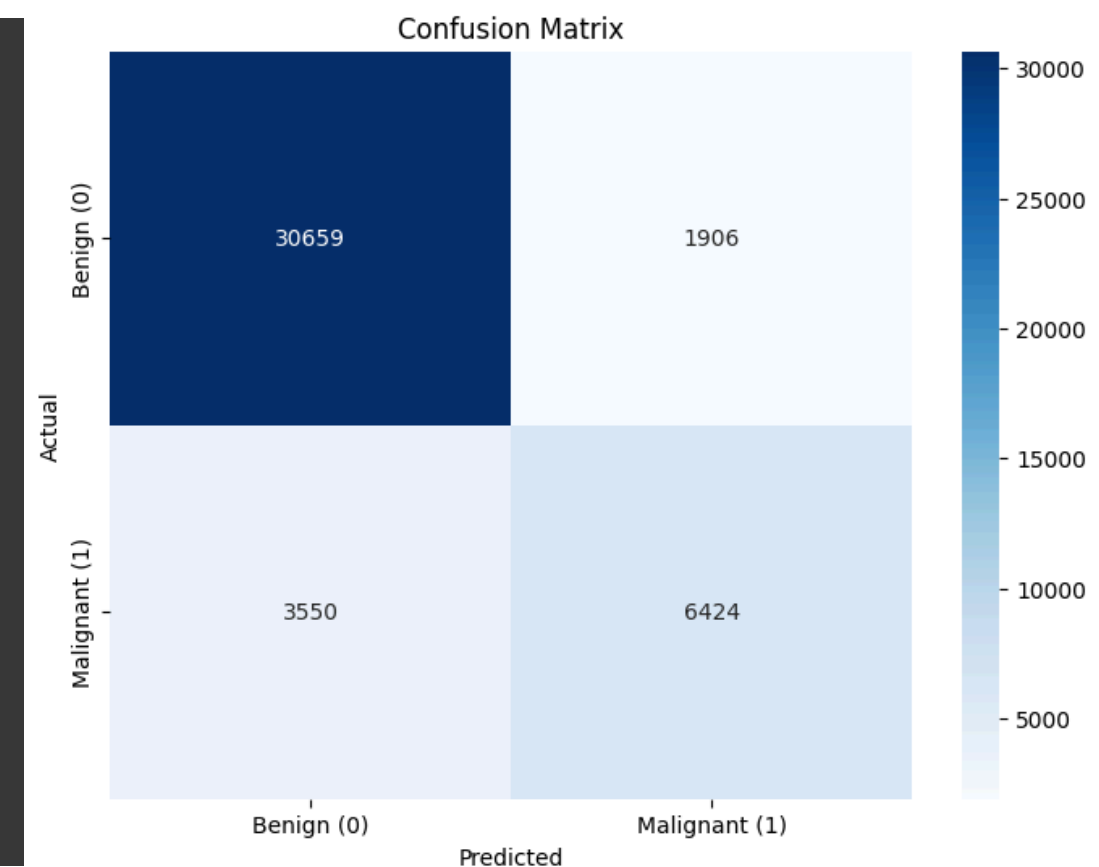
```
Best Parameters: {'var_smoothing': 1e-05}
Best F1 Score (Malignant): 0.6957226036683019
Cross-validation ROC-AUC scores: [0.93965517 0.93844039 0.93769004 0.9372847 0.93824306]
Mean CV ROC-AUC: 0.9382626716728923
Mean CV Accuracy: 0.870451125645212
```

```
Classification Report:
              precision    recall  f1-score   support

     0       0.90         0.94         0.92       32565
     1       0.77         0.64         0.70        9974

 accuracy          0.87         0.87         0.87       42539
 macro avg         0.83         0.79         0.81       42539
 weighted avg      0.87         0.87         0.87       42539
```

```
Test Set Accuracy: 0.8717412256987705
Test Set ROC-AUC Score: 0.9387874341551508
```



# LOGISTIC REGRESSION


## Result

Best Parameters: {'C': 0.1, 'class\_weight': None}  
Best F1 Score (Malignant): 0.7051541575702261  
Cross-validation ROC-AUC scores: [0.94099876 0.94022144 0.93939208 0.93917683 0.93993571]  
Mean CV ROC-AUC: 0.9399449628375189  
Mean CV Accuracy: 0.8842917034737987

Classification Report:

	precision	recall	f1-score	support
0	0.89	0.97	0.93	32565
1	0.87	0.60	0.71	9974
accuracy			0.89	42539
macro avg	0.88	0.79	0.82	42539
weighted avg	0.88	0.89	0.88	42539

Test Set Accuracy: 0.885869437457392  
Test Set ROC-AUC Score: 0.9406589668067115



# MODEL SELECTION

Model	Precision	Recall	F1-Score	Accuracy	ROC-AUC
Decision Tree	0.93	0.84	0.87	0.9157	0.9157
Naive Bayes (Gaussian)	0.83	0.79	0.81	0.8705	0.9383
Logistic Regression	0.88	0.79	0.82	0.8843	0.9399



# MODEL SELECTION

Model	Accuracy	ROC-AUC
Decision Tree	0.9178	0.9600
Naive Bayes (Gaussian)	0.8717	0.9388
Logistic Regression	0.8859	0.9407

# THANK YOU

FOR YOUR ATTENTION



นางสาวพรรณรณมณ ราชคมน์	653020213-2
นางสาวสิริญาพร รสจันทร์	653020218-2
นางสาวพรวลัย ฝ็อกซ์ออล	653020573-2

